Mineração de métricas DORA em repositórios públicos

Disciplina: Laboratório de Experimentação de Software
Professor: Danilo Maia
Grupo: Ana, Bruna e Walter
Repositório: github.com/bruna-bernardes/Lab_Experimentacao_Software

1. Introdução

As métricas DORA avaliam velocidade e estabilidade da entrega de software. Este estudo calcula essas métricas a partir de repositórios públicos do GitHub que usam GitHub Actions. Uma release publicada é o proxy de deploy, uma execução de workflow é o proxy de integração contínua e a data do autor do commit é a origem do lead time. Como o GitHub não registra deploys nem incidentes de produção, os valores são aproximações e a classificação depende da definição operacional adotada.

1.1 Questões de pesquisa e hipóteses

RQ01. Qual a frequência de deploy dos repositórios populares que usam CI/CD? Esperamos grande dispersão entre projetos.

RQ02. Qual o tempo entre commit e deploy? Esperamos que a variante por release seja maior que a variante por commit, porque ela usa o commit mais antigo de cada release.

RQ03. Qual a taxa de falha? Esperamos diferenças entre o proxy de falha de CI e o proxy de releases corretivas.

RQ04. Qual o tempo de recuperação? Esperamos heterogeneidade entre os repositórios.

RQ05. Frequência maior implica maior taxa de falha? Esperamos que velocidade e estabilidade não apresentem uma relação monotônica forte.

RQ06. Quais características estão associadas ao desempenho? Esperamos associações com linguagem, popularidade e idade.

RQ07. A classificação depende da definição operacional? Esperamos que parte dos repositórios mude de categoria entre variantes.

2. Metodologia

2.1 Amostra e coleta

A janela de observação vai de 1º de outubro de 2025 a 30 de setembro de 2026 (cerca de 52,1 semanas). Entraram repositórios públicos, não arquivados e que não são forks, com mais de 1.000 estrelas, GitHub Actions, pelo menos cinco releases publicadas e pelo menos 50 workflow runs válidas no branch padrão, disparadas por `push`. A busca foi fatiada por faixas de estrelas e o pool foi embaralhado com semente 42. O pipeline pediu 320 repositórios para manter margem sobre o mínimo de 300.

Etapa	Repositórios
População da busca	60.162
Candidatos examinados	2.255
Sem GitHub Actions	934
Com GitHub Actions	1.320
Menos de 5 releases	886
Menos de 50 runs válidas	114
Erros persistentes	1
Amostra final	**320**

Drafts ficaram de fora. A definição principal de deploy usa releases com `prerelease = false`. A data do commit é `commit.author.date`. Runs com conclusão `cancelled`, `skipped`, `neutral`, `action_required`, `stale` ou vazia foram ignoradas. Falha de CI reúne `failure`, `timed_out` e `startup_failure`.

No lead time, 59 releases foram a primeira da história do repositório e ficaram de fora dessa métrica. Outras 15, em 12 repositórios, não tiveram comparação disponível. Houve 5.330 releases com comparação e nenhum commit novo, e 402 commits com data posterior à publicação, descartados do cálculo.

2.2 Definições operacionais

A frequência de deploy é o número de releases da janela dividido por 52,1 semanas. O lead time por release é a mediana, entre as releases, da diferença entre `published_at` e o commit mais antigo incluído na release. O lead time por commit é a mediana de `published_at` menos a data de cada commit incluído. O CFR de CI é a proporção de runs com falha entre falhas e sucessos. O CFR de entrega é a proporção de releases seguidas, em até 7 dias, por uma release corretiva. Releases dos últimos 7 dias da janela ficam fora do denominador: foram 547 releases, em 105 repositórios. O tempo de recuperação é a mediana, por repositório, da diferença entre o `updated_at` do primeiro sucesso e o `run_started_at` da primeira falha do episódio, dentro de cada workflow.

A heurística do dataset (versão v1) marca a release seguinte como corretiva quando a versão muda apenas o *patch* e há ao menos um commit com `fix`, `hotfix`, `bugfix` ou `revert`. Se a tag não segue o versionamento semântico, a decisão usa só as mensagens.

Todas as estatísticas descritivas usam mediana e intervalo interquartil. A classificação DORA usa os cortes fixos da disciplina:

Métrica	Elite	High	Medium	Low
Frequência	≥ 7 por semana	≥ 1 e < 7 por semana	≥ 1 por mês e < 1 por semana	< 1 por mês
Lead time	< 1 dia	1 dia a < 1 semana	1 semana a < 30 dias	≥ 30 dias
Change failure rate	≤ 15%	> 15% e ≤ 30%	> 30% e ≤ 45%	> 45%
Recuperação	< 1 hora	1 hora a < 1 dia	1 dia a < 1 semana	≥ 1 semana

A categoria geral atribui 4 pontos a Elite, 3 a High, 2 a Medium e 1 a Low. O resultado é a mediana desses pontos, arredondada para baixo. Quando não há episódio de recuperação encerrado, a mediana usa as métricas disponíveis.

2.3 Amostra-ouro

A amostra-ouro tem 60 repositórios sorteados com `random_state = 42` e 300 releases (cinco por repositório). Três avaliadores rotularam, de forma independente, o tipo do projeto, se as releases representam entregas reais e se cada release sorteada é corretiva. O consenso usou unanimidade, maioria simples e, nos empates 1-1-1, decisão de reunião registrada em `validacao/decisoes_reuniao.csv`.

Dimensão	n	Kappa de Fleiss	Interpretação	Concordância unânime
Tipo de projeto	60	0,518	moderada	80,0%
Entregas reais	60	−0,040	pobre	40,0%
Release corretiva	300	0,369	razoável	52,7%

O consenso de tipo reuniu 48 rótulos unânimes e 12 por maioria: 54 bibliotecas ou frameworks, 5 aplicações ou serviços e 1 ferramenta de linha de comando. O consenso de entregas reais reuniu 24 unânimes, 32 por maioria e 4 decisões de reunião: 51 sim, 5 incerto e 4 não. O consenso de releases corretivas reuniu 158 unânimes e 142 por maioria.

Versão	Regra	Precisão	Recall	F1
v1	patch e ao menos um commit de correção	0,833	0,611	0,705
v2	patch e pelo menos metade dos commits de correção	0,810	0,198	0,318
v3	apenas mudança de patch	0,828	0,756	0,790

O dataset e as análises usam a versão v1.

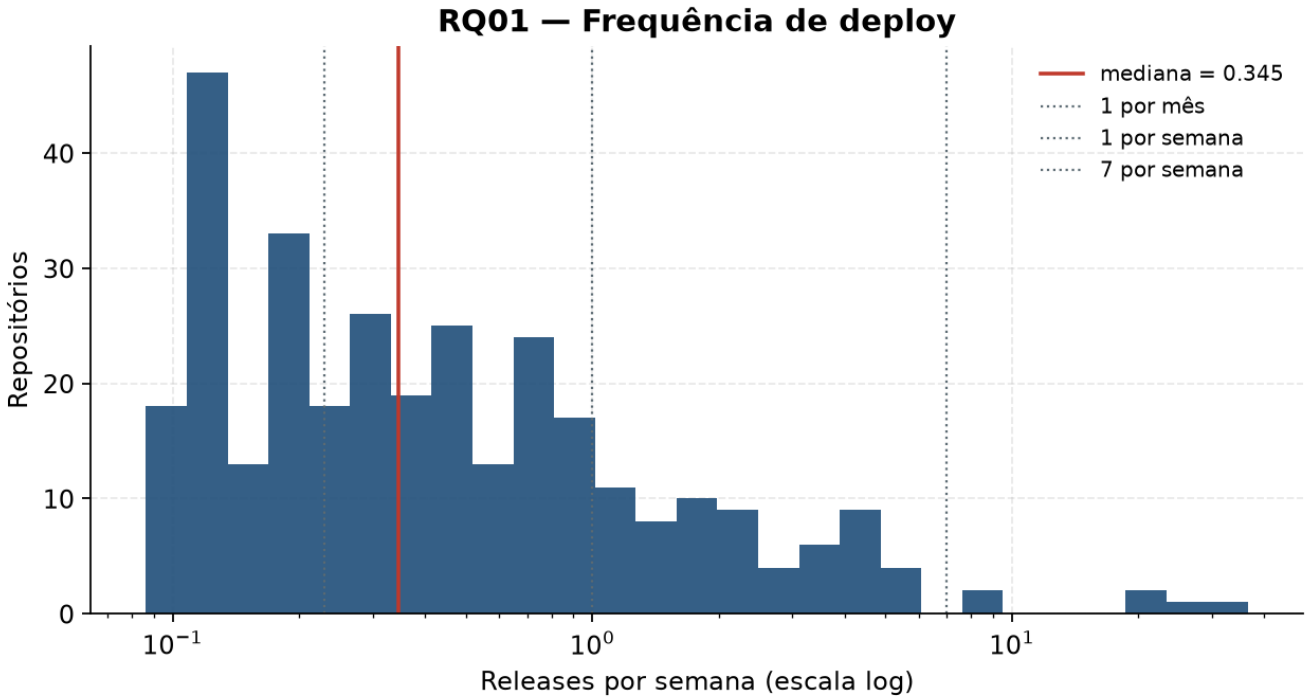
3. Resultados

As figuras e as tabelas desta seção foram geradas por `python analise_sprint3.py` e estão em `resultados/sprint3/`.

3.1 RQ01 — Frequência de deploy

A mediana foi **0,345 releases por semana**, o que corresponde a **18 releases** na janela. O primeiro quartil foi 0,173 (9 releases), o terceiro foi 0,901 (47 releases) e o IQR foi 0,729. A distribuição é assimétrica: a maior parte da amostra publica menos de uma release por semana, e poucos repositórios passam de uma por dia.

Elite	High	Medium	Low
6	61	132	121



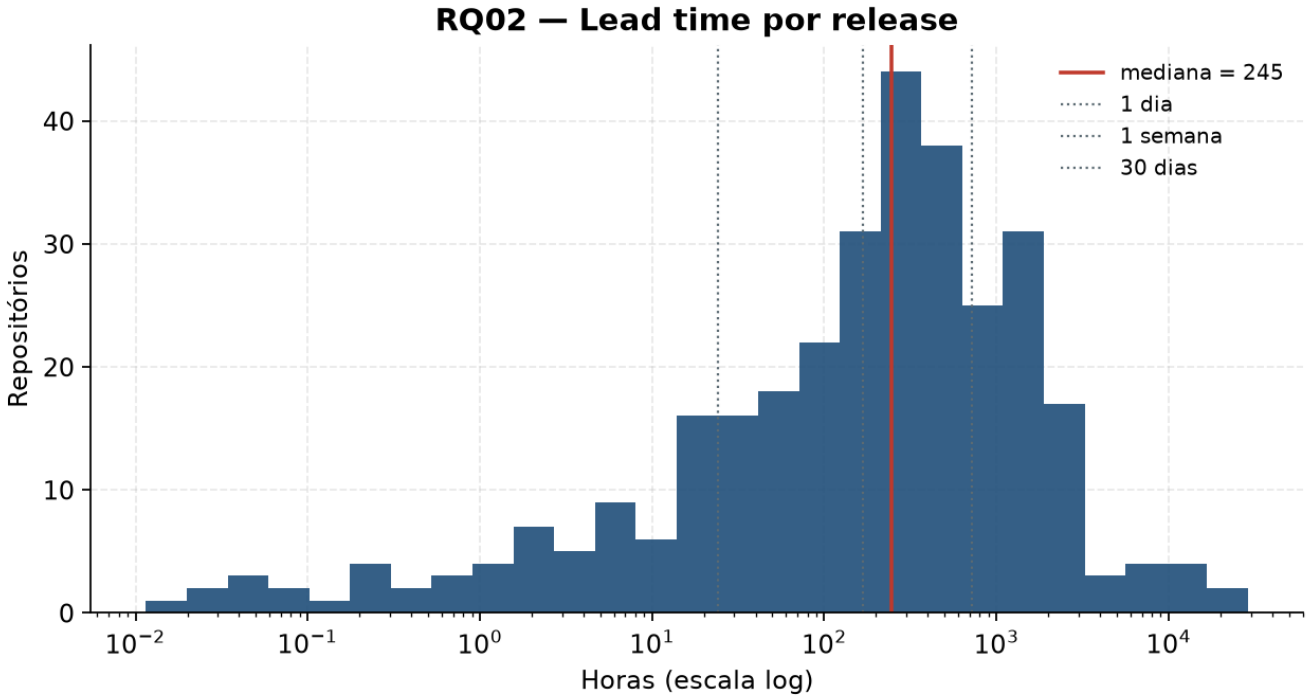
Frequência de deploy em escala logarítmica, com a mediana e os cortes de uma release por mês, por semana e sete por semana

3.2 RQ02 — Lead time

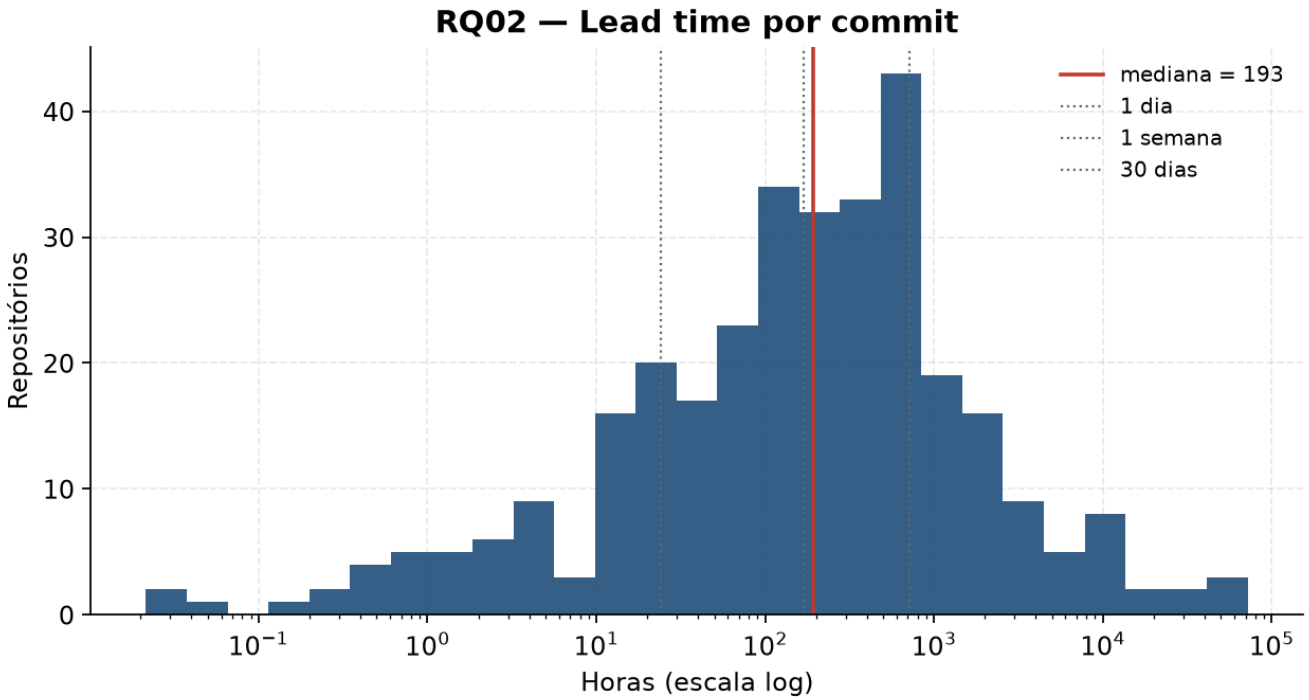
Variante	n	Mediana	Q1	Q3	IQR
Por release	320	245 h (10,2 dias)	41 h (1,7 dia)	761 h (31,7 dias)	720 h
Por commit	320	193 h (8,1 dias)	45 h (1,9 dia)	674 h (28,1 dias)	628 h

As duas medianas caem na faixa Medium (de uma semana a menos de 30 dias). A variante por release é maior, como previsto: um commit antigo eleva o valor da release inteira, enquanto a variante por commit dilui esse efeito entre todos os commits.

Na variante por release, 65 repositórios são Elite, 69 High, 105 Medium e 81 Low.



Lead time por release em horas, escala logarítmica

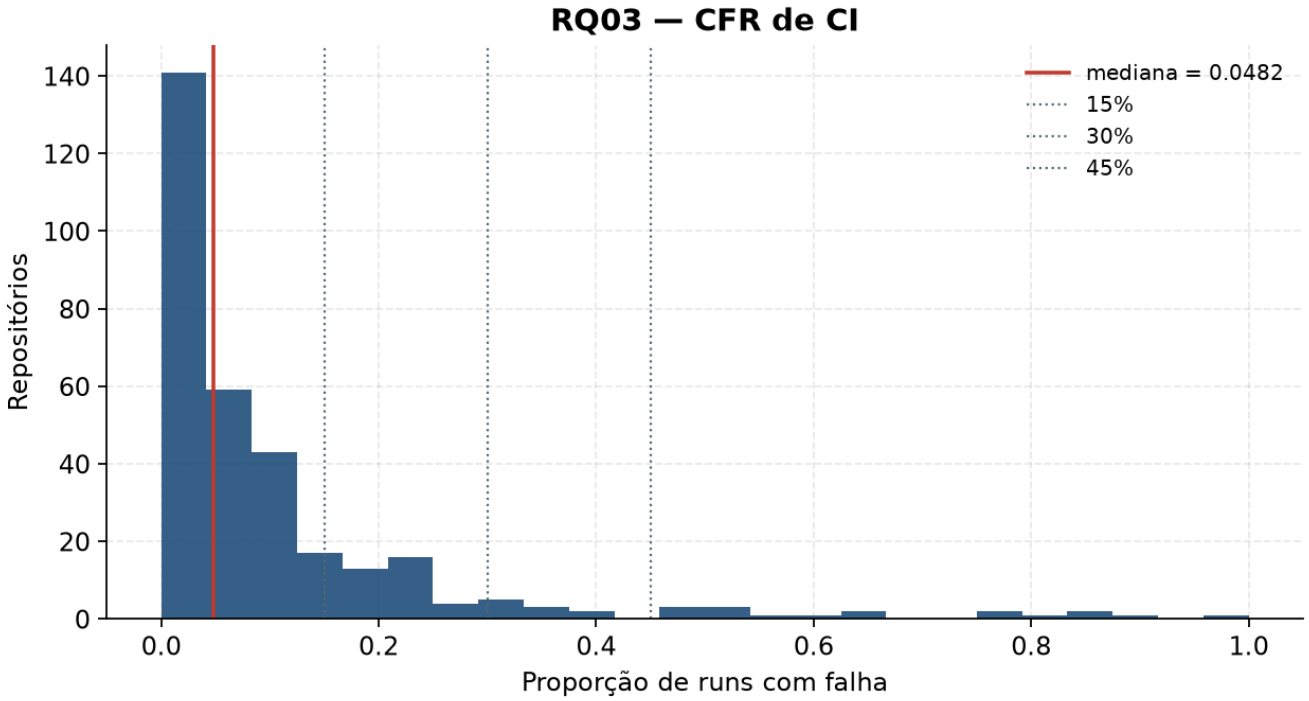


Lead time por commit em horas, escala logarítmica

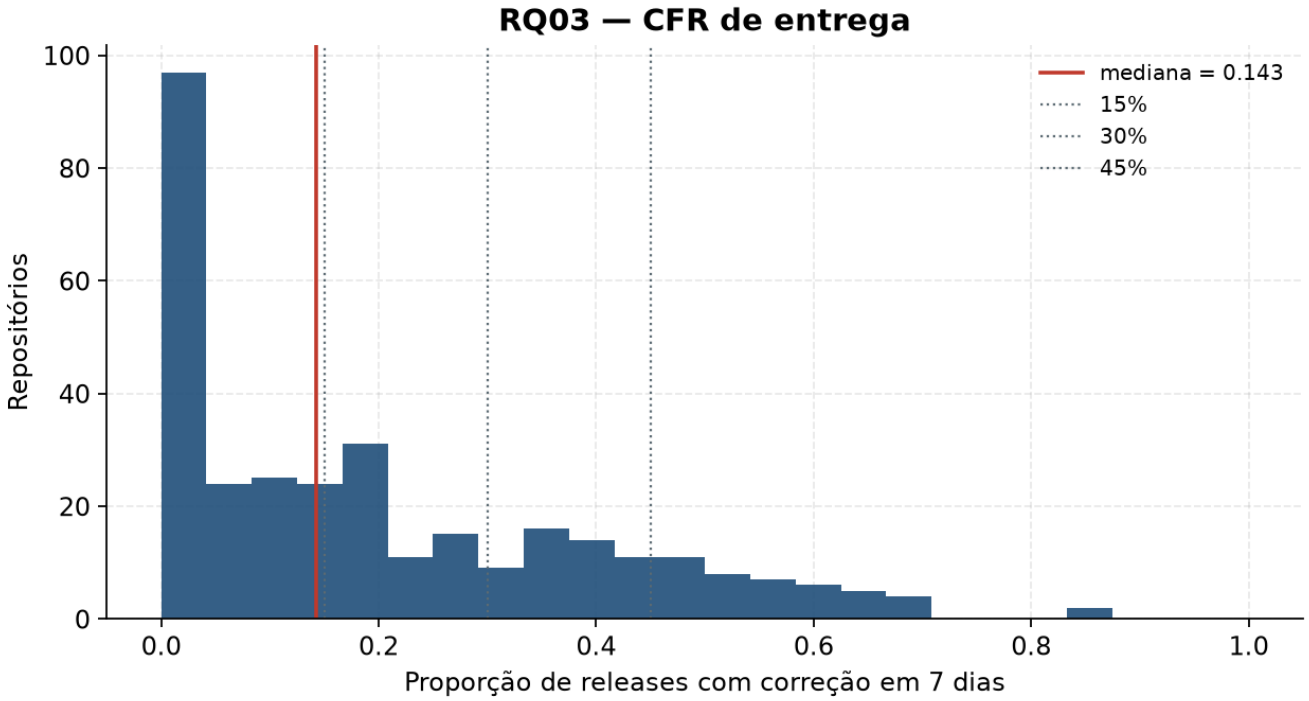
3.3 RQ03 — Change failure rate

Variante	n	Mediana	Q1	Q3	IQR
CFR de CI	320	4,8%	2,1%	12,2%	10,1 p.p.
CFR de entrega	320	14,3%	0%	33,3%	33,3 p.p.

O CFR de CI tem mediana Elite e é concentrado: 253 repositórios ficam em até 15%. O CFR de entrega tem mediana também Elite, no limite da faixa, e é bem mais disperso: 165 Elite, 64 High, 47 Medium e 44 Low. Falha de pipeline e release corretiva produzem distribuições diferentes.



Histograma do CFR de CI com os cortes de 15%, 30% e 45%

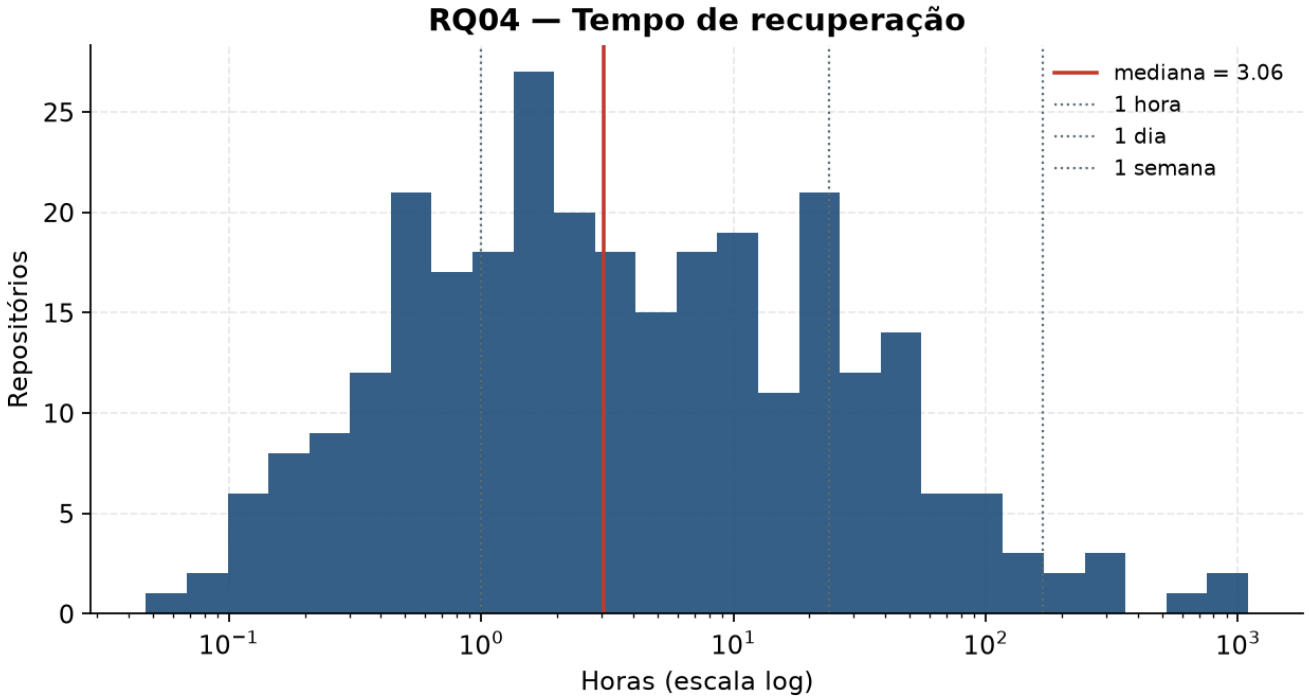


Histograma do CFR de entrega com os cortes de 15%, 30% e 45%

3.4 RQ04 — Tempo de recuperação

Houve mediana em 292 repositórios: **3,06 horas**, com Q1 de 0,87 hora, Q3 de 16,8 horas e IQR de 15,9 horas. A mediana cai na faixa High (de 1 hora a menos de 1 dia). Dos episódios observados, 15.918 foram encerrados por um sucesso e 116 permaneceram abertos até o fim da janela (0,7% dos episódios), em 71 repositórios. Vinte e oito repositórios não tiveram episódio encerrado e ficam sem mediana.

Elite	High	Medium	Low	Sem episódio encerrado
80	157	46	9	28



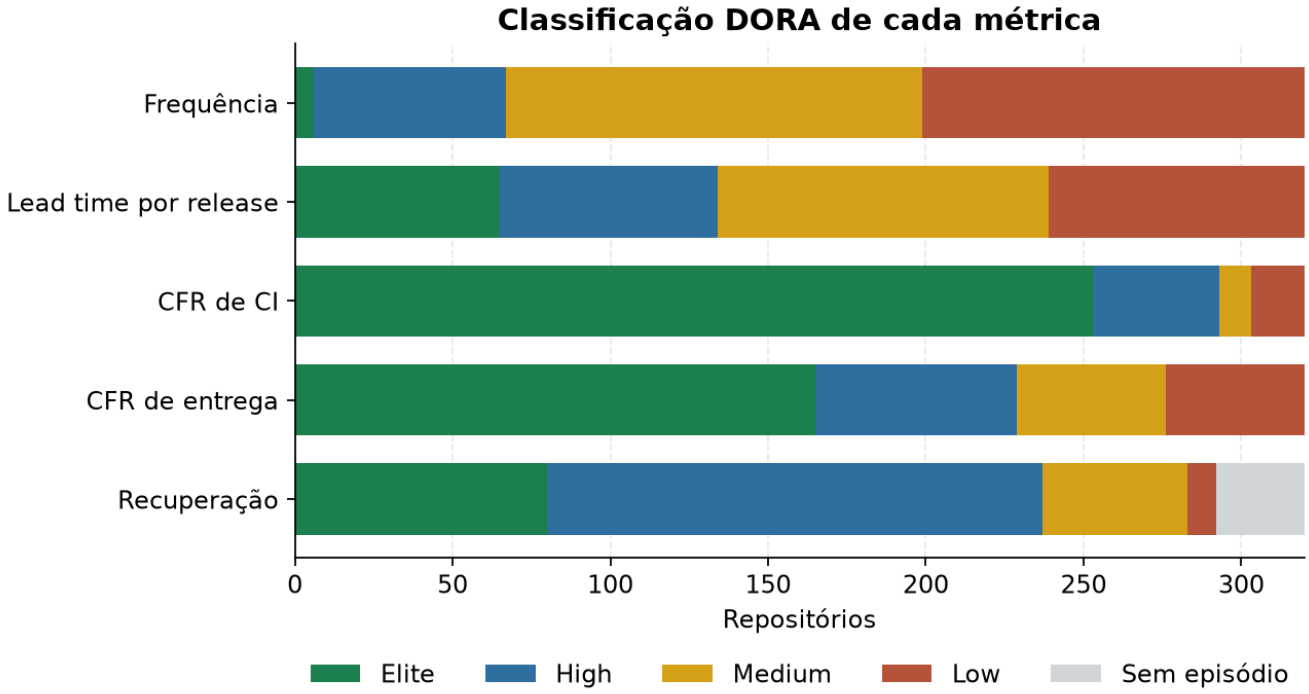
Tempo de recuperação em horas, escala logarítmica

3.5 Classificação de referência

Na combinação C1 (frequência, lead time por release, CFR de CI e recuperação), a categoria geral dos 320 repositórios é:

Elite	High	Medium	Low
25 (7,8%)	125 (39,1%)	142 (44,4%)	28 (8,8%)

A figura abaixo separa as quatro métricas. A estabilidade medida pelo CI concentra a amostra em Elite e High. A velocidade, sobretudo a frequência, concentra a amostra em Medium e Low. A categoria geral, que usa a mediana das quatro notas, fica por isso em Medium ou High para a maior parte dos repositórios.

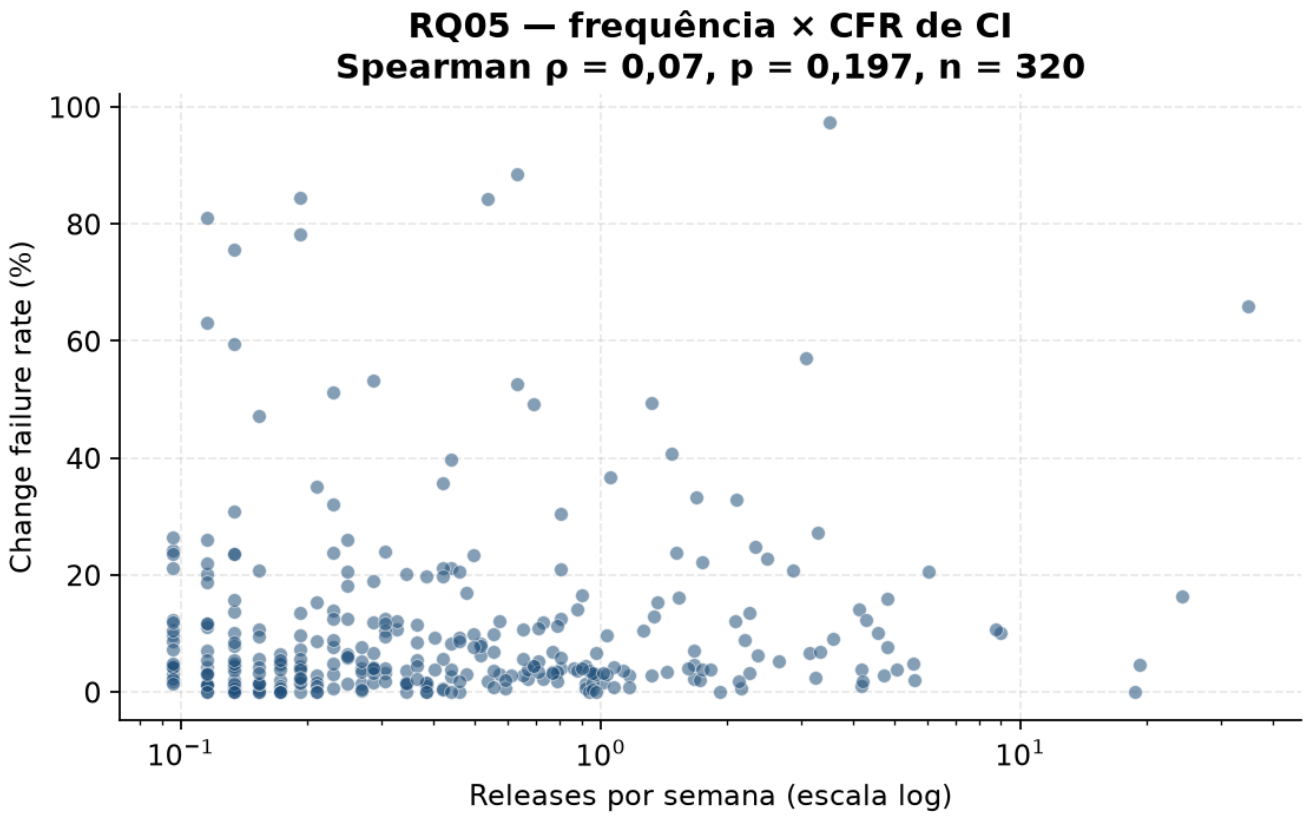


Barras empilhadas da classificação DORA de frequência, lead time, CFR de CI, CFR de entrega e recuperação

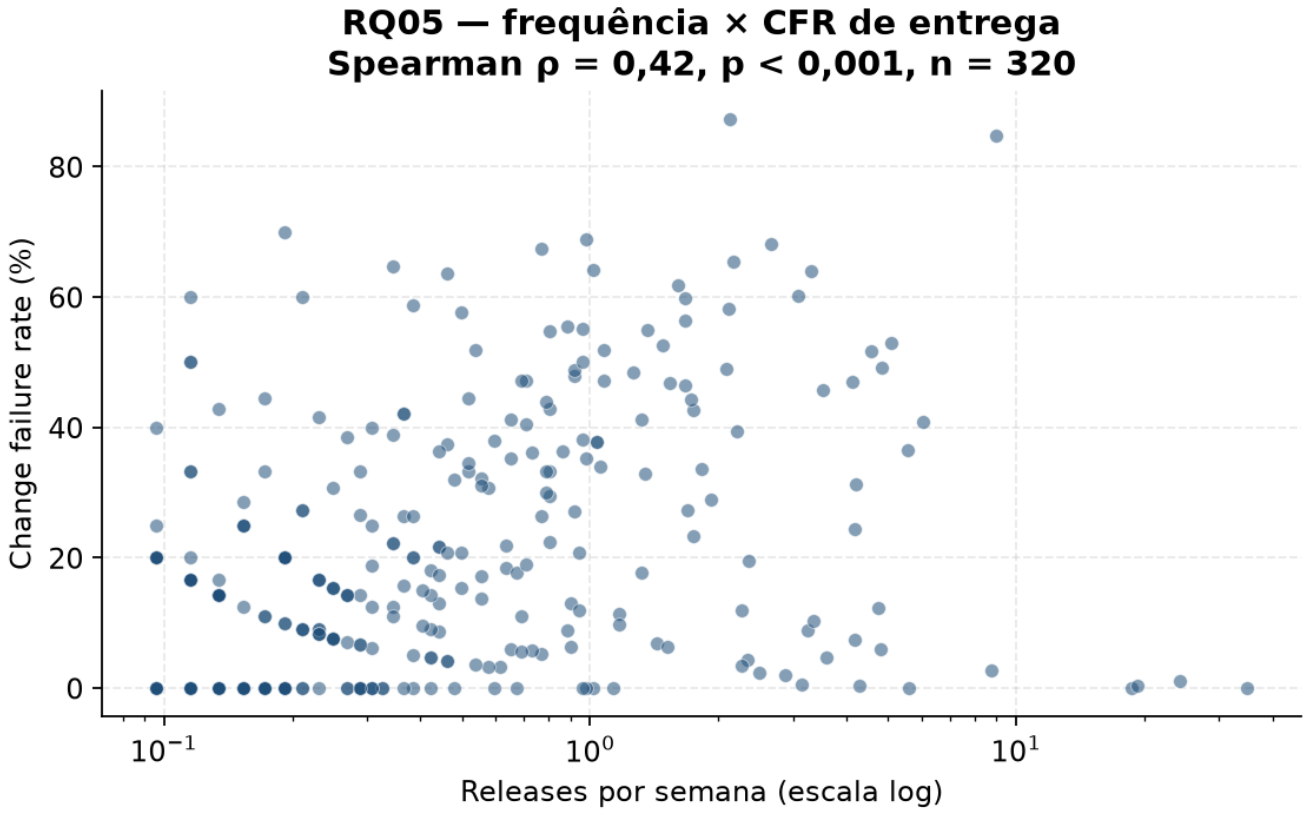
3.6 RQ05 — Frequência e taxa de falha

CFR	n	Spearman ρ	p-valor
CI	320	0,072	0,197
Entrega	320	0,422	< 0,001

Não há associação monotônica detectável entre frequência e CFR de CI. Há associação positiva moderada entre frequência e CFR de entrega: repositórios que publicam mais vezes também tendem a ter mais releases seguidas por uma correção em até sete dias. A associação descreve a ordem dos valores e não estabelece causa.



Dispersão entre frequência e CFR de CI, com eixo horizontal em escala logarítmica



Dispersão entre frequência e CFR de entrega, com eixo horizontal em escala logarítmica

3.7 RQ06 — Características associadas

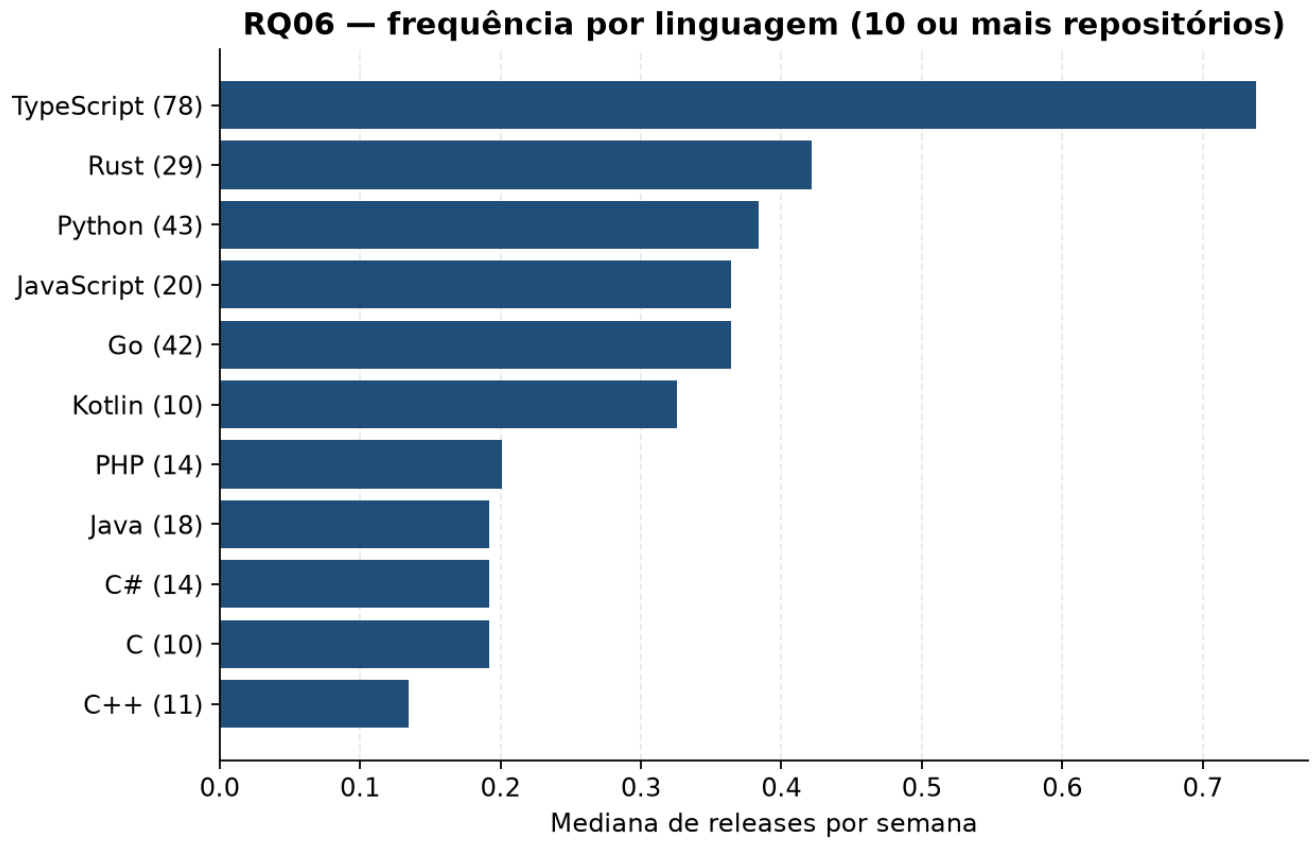
Os fatores foram a linguagem principal, os quartis de estrelas, os quartis de idade e o tipo de projeto da amostra-ouro. Para cada fator e cada métrica aplicou-se Kruskal-Wallis, ou Mann-Whitney quando havia dois grupos. Os 24 p-valores foram corrigidos por Holm. O tamanho de efeito do Kruskal-Wallis é $\varepsilon^2 = H / (n - 1)$.

Permaneceram significativas, com p de Holm inferior a 0,001:

Fator	Métrica	ε^2
Linguagem	Frequência	0,157
Linguagem	Lead time por release	0,174
Linguagem	Lead time por commit	0,154
Idade	Frequência	0,144
Idade	Lead time por release	0,215
Idade	Lead time por commit	0,214
Idade	CFR de entrega	0,193

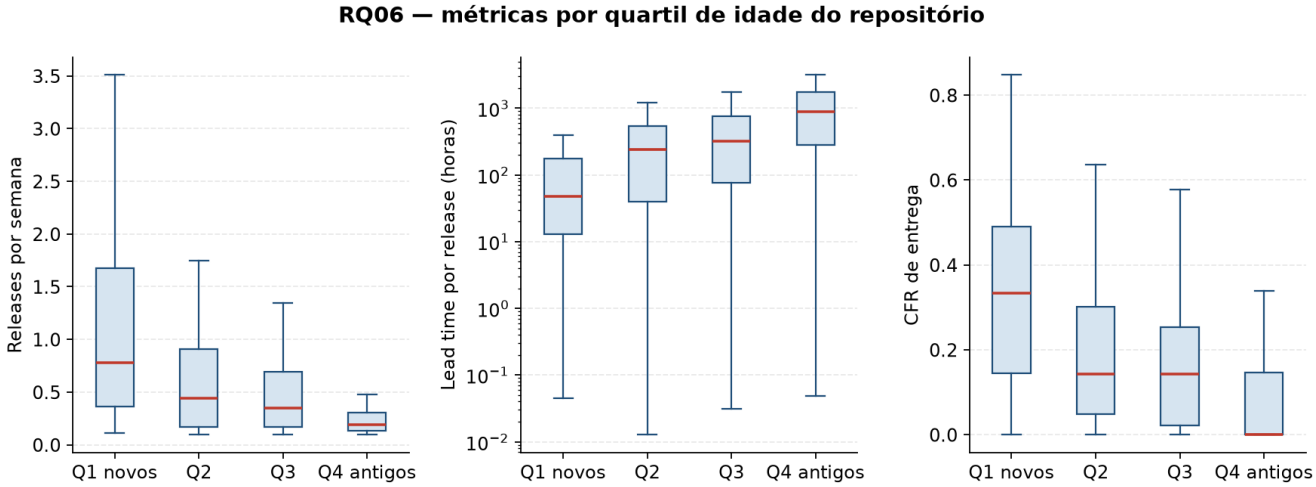
Os quartis de estrelas não mostraram diferença significativa em nenhuma métrica. O quartil menos popular vai de 1.011 a 1.501 estrelas e o mais popular, de 8.616 a 213.942.

Entre as linguagens com pelo menos 10 repositórios, a mediana de frequência vai de 0,74 release por semana em TypeScript (78 repositórios) a 0,13 em C++ (11). Java, C# e C ficam próximas de 0,19.



Mediana da frequência de deploy por linguagem

A idade vai, no quartil mais novo, de 7 a 723 dias e, no mais antigo, de 3.647 a 6.316 dias. As medianas de frequência nesses quartis são 0,78, 0,44, 0,35 e 0,19 release por semana. As medianas de lead time por release são 48, 241, 322 e 877 horas. As medianas de CFR de entrega são 33%, 14%, 14% e 0%. Repositórios mais novos publicam com mais frequência, com lead time menor e com mais releases corretivas em até sete dias.



Boxplots de frequência, lead time e CFR de entrega por quartil de idade

Na amostra-ouro, a comparação entre as 5 aplicações ou serviços e as 54 bibliotecas ou frameworks não permaneceu significativa após Holm em nenhuma métrica. A ferramenta de linha de comando é um único repositório.

3.8 RQ07 — Sensibilidade da classificação

Três combinações usam as variantes já calculadas no dataset:

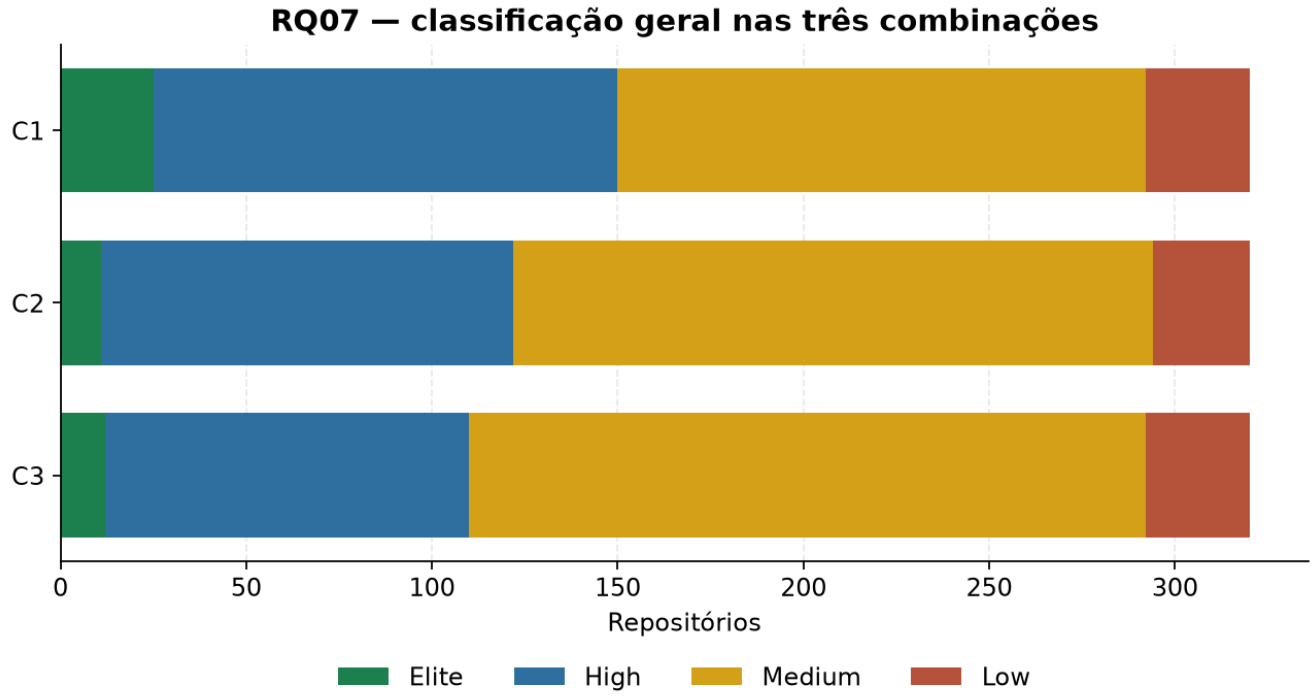
Combinação	Lead time	CFR
C1	por release	de CI
C2	por commit	de entrega
C3	por release	de entrega

A frequência e o tempo de recuperação são os mesmos nas três. A categoria geral muda assim:

Comparação	Mudaram de categoria	Percentual	Kappa ponderado
C1 × C2	108/320	33,8%	0,52
C1 × C3	71/320	22,2%	0,70
C2 × C3	57/320	17,8%	0,73

Combinação	Elite	High	Medium	Low
C1	25	125	142	28
C2	11	111	172	26
C3	12	98	182	28

O kappa entre 0,52 e 0,73 indica concordância de moderada a substancial. A maior troca ocorre quando lead time e CFR mudam ao mesmo tempo. Trocar só o proxy de falha, de C1 para C3, move 22,2% dos repositórios e reduz a parcela High de 125 para 98, engrossando a parcela Medium.



Classificação geral nas combinações C1, C2 e C3

4. Discussão

A dispersão prevista na frequência aparece nos números: o intervalo entre o primeiro e o terceiro quartil vai de 9 a 47 releases no ano, e 253 dos 320 repositórios ficam abaixo de uma release por semana. A hipótese do lead time também se confirma. A mediana por release (10,2 dias) supera a mediana por commit (8,1 dias), e as duas continuam na mesma faixa DORA.

Os dois CFRs respondem a perguntas diferentes. O de CI tem mediana de 4,8% e coloca 253 repositórios em Elite. O de entrega tem mediana de 14,3% e IQR de 33 pontos percentuais. A hipótese de que os proxies divergem fica sustentada pela classificação e pela correlação. Frequência e CFR de CI têm $\rho = 0,07$ ($p = 0,197$). Frequência e CFR de entrega têm $\rho = 0,42$ ($p < 0,001$). No proxy de pipeline, velocidade e estabilidade caminham sem uma relação monotônica. No proxy de release corretiva, publicar mais vezes acompanha uma taxa maior de correções em até sete dias. Isso é compatível com políticas de release diferentes, e a correlação não indica que deploys frequentes causem falhas de produção.

Linguagem e idade separam os grupos; a popularidade, dentro da faixa acima de 1.000 estrelas, não. O efeito mais claro é o da idade: projetos mais novos concentram frequência mais alta, lead time mais curto e CFR de entrega mais alto. Os ε^2 significativos ficam entre 0,14 e 0,21. São associações de grupo, não efeitos causais.

Na classificação geral de referência, 44,4% dos repositórios são Medium e 39,1% são High. Esse resultado mistura uma estabilidade de CI alta com uma frequência baixa. Entre as três combinações, de 17,8% a 33,8% dos repositórios mudam de categoria. A ordenação relativa se mantém em boa parte (kappa de 0,52 a 0,73), e a etiqueta Elite, High, Medium ou Low de um repositório precisa nomear a definição que a produziu.

5. Ameaças à validade

Construto. Release publicada aproxima deploy, e falha de workflow aproxima falha em produção. Na amostra-ouro, o consenso considerou que as releases representam entregas reais em 51 dos 60 repositórios, com 5 incertos e 4 negativos. A concordância dessa dimensão foi pobre ($\kappa = -0{,}04$), então o próprio critério é ambíguo. A heurística v1, usada no CFR de entrega, tem precisão de 0,83, recall de 0,61 e F1 de 0,70 frente ao consenso, e o kappa entre avaliadores nessa dimensão foi 0,37.

Interna. Idade e linguagem estão associadas às métricas, e a análise não separa esses fatores de política de release, tamanho da equipe ou número de workflows. Rebases e *squash merges* podem alterar `commit.author.date`; 402 commits tiveram data posterior à publicação e foram descartados. Repositórios mais antigos acumulam mais história de release, o que pode alongar o lead time por release.

Externa. A amostra reúne 320 projetos públicos com mais de 1.000 estrelas, extraídos de uma busca com 60.162 repositórios. Projetos privados, corporativos ou menos populares podem ter outro ritmo de release e outro uso de GitHub Actions.

Conclusão. A correção de Holm reduz o risco de falso positivo nas 24 comparações da RQ06. O tipo de projeto foi observado em 60 repositórios, com 54 bibliotecas ou frameworks. Mediana e IQR foram escolhidos porque as distribuições são assimétricas. A classificação geral muda para 17,8% a 33,8% dos repositórios quando a variante de lead time ou o proxy de falha muda, então uma conclusão presa a uma única etiqueta DORA é sensível a essa escolha.

6. Materiais

O pipeline roda, a partir de `Laboratorio_03`, com:

```
python -m pipeline --config config.json
```

O token é lido da variável `GITHUB_TOKEN`. O dataset está em `resultados/dataset_final.csv` e o dicionário de colunas em `resultados/dicionario_dados.md`. A subamostra fixa de 30 repositórios, sorteada com semente 42, está em `resultados/replicacao/amostra_30.csv`.

7. Conclusão

Nos 320 repositórios, a frequência mediana é de 18 releases em doze meses e o lead time mediano fica entre 8 e 10 dias, conforme a variante. O CFR de CI tem mediana de 4,8% e o de entrega, de 14,3%. O tempo mediano de recuperação é de 3,06 horas. A categoria geral mais comum na definição de referência é Medium (142 repositórios), seguida de High (125).

Velocidade e falha de CI não se associam. Velocidade e release corretiva se associam de forma positiva e moderada. Linguagem e idade acompanham diferenças de frequência e de lead time; a contagem de estrelas, dentro desta amostra, não. De 17,8% a 33,8% dos repositórios mudam de categoria DORA quando a definição de lead time ou de falha muda.

Referências

- Forsgren, N.; Humble, J.; Kim, G. *Accelerate: The Science of Lean Software and DevOps*. IT Revolution, 2018.
- DORA. *Software delivery metrics: the four keys*. https://dora.dev/guides/dora-metrics-four-keys/
- Wohlin, C. et al. *Experimentation in Software Engineering*. Springer, 2012.
- Landis, J. R.; Koch, G. G. The measurement of observer agreement for categorical data. *Biometrics*, 1977.
- Romano, J. et al. Appropriate statistics for ordinal level data. 2006.